Лекция 1

Файловые системы

1.1 Носители

1.1.1 HDD

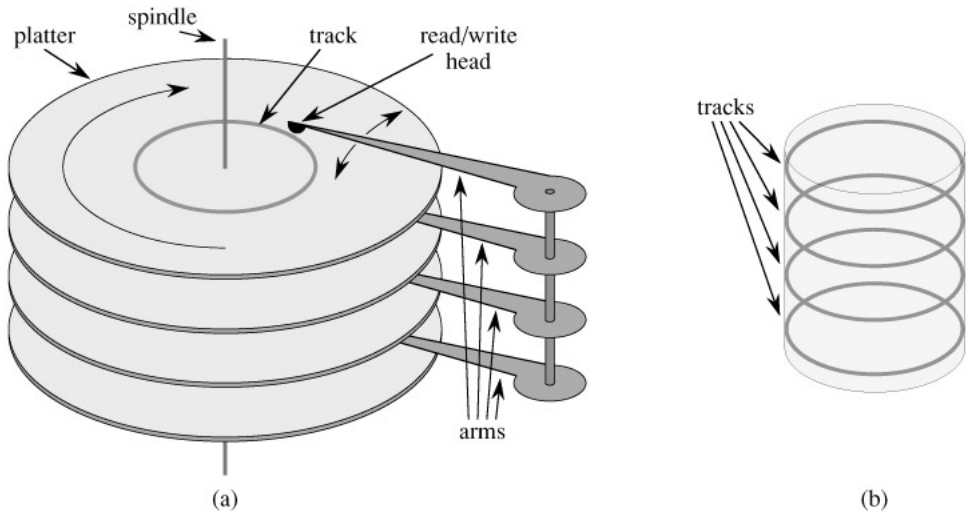

Рис. 1.1: Жесткий диск

- Обороты в минуту(O) — 5400, 7200, 10000, ...
- $\frac{1}{2*O}$ — минимальное время доступа (случайное чтение)
- В мире Unix не существует дефрагментации (ОС должна сама заботиться)
- Время отказа (**MTBF** — min time before failure) — условное количество циклов наработки до отказа
- На **server** — сутки, **desktop** — часы (разница примерно в 3 раза, если одно и то же число циклов)
- Плюсы: стоимость, объем
- Минусы: время доступа, надежность

1.1.2 SSD

- **SATA** и **NVME** — протоколы для дисков
- **NVME** — новомодная штука для **SSD**
- Плюсы: время доступа
- Минусы: надежность, стоимость, объем

1.1.3 Общее

- **IOPS** — input/output operations per second

  Показатель применяется для сравнения, например, какого-нибудь **HDD** с **SSD**
- **seek** — рандомное чтение (512 байт)
- Минимум информации: сектор — 512 байт -> 4096 байт
- Чтение одного байта равносильно чтению всего сектора с этим байтом
- Запись одного байта — считать один сектор, заменить байт и записать один сектор
- Аналогия — процессор-память — **cacheline**

  (кэшируется линиями, а на диск записывается и считывается секторами)

1.2 Быстродействие

1.2.1 Интересные числа

Числа, которые должен знать каждый программист

Cycle	1 ns
Main memory reference	100 ns
Read 4K randomly from SSD	150 us
Read 1 MB sequentially from SSD	1 ms
Disk seek	10 ms
Read 1 MB sequentially from disk	20 ms

1.2.2 Выводы для HDD

- Читать нужно последовательно
- Обращения к диску следует минимизировать
- Стоимость доступа сильно дороже передачи данных

1.3 Structure packaging

Сколько будет занимать памяти следующая структура?

hole1.c

```
struct hole {
    uint64_t a;
    uint32_t b;
    uint64_t c;
    uint32_t d;
}
```

Ответ: 32 байта, так как b и d будут выравнены по MAX_ALLIGNMENT
Очевидное решение проблемы:

hole2.c

```
struct hole {
    uint64_t a;
    uint32_t b;
    uint32_t d;
    uint64_t c;
}
```

Данная структура будет занимать 24 байта на x86_64.

1.4 Алгоритмы элеватора

Ссылка на презентацию

1. SLIDE 6

   Алгоритмы элеватора обрабатывают последовательности запросов к диску (переупорядочивают их)

2. SLIDE 7

   FCFS (FIFO) — самый простой и медленный

3. SLIDE 8-9

   SSTF (Shortest Seek Time First)— сортировка (очередной запрос определяется наименьшим временем seek)

4. SLIDE 10 - ...

   Различные способы упорядочивания(**SCAN**)

1.5 Файл

- Абстракция для данных (для Kernelspace)
- Последовательность байтов (для Userspace)
- Формат не определен
- **Unix** — все есть файл (абстракция-интерфейс внутри ядра)
- Типы файлов
  - regular
  - directory
  - symlink
  - socket, fifo
  - character device, block device

1.6 Директория

- Содержит имена находящихся в ней файлов
- . — ссылка на текущую
- .. — ссылка на родителя
- **$ cd** — сменить директорию
- **$ pwd** — текущая директория
- **$ ls** — формирование дерева
- **$ find** — поиск
- *filename vs pathname*: **$ realpath**

1.6.1 Права — просто числа

- **$ view /etc/passwd**
- **$ view /etc/group**
- **$ id** - показывает идентификаторы того, кто ее вызывал
- **$ execute** — search
- **$ read** — directory listing
- **$ write** — changing directory

- Темные директории (переход в директорию внутри директории, для который ты не можешь посмотреть все файлы)
- Права rwx (read, write, execute)
- **$ chmod** — меняет права доступа

  $ chmod 123 — 1 - user, 2 - group, 3 - other
- У процесса есть информация о том, кто его запустил
- **SGID** (**S**et **G**roup **ID** up on execution)

  Специальный тип прав, который временно выдается запускающему (у него теперь права группы на файл/директорию)

1.6.2 sticky bit

- Изменение поведения при создании нового файла
- /tmp
- Создаешь директорию со *sticky bit* и все, кто создают файлы в этой директории имеют на них права

1.7 Иерархия

- /
  - bin/
  - dev/
  - etc/
  - sbin/
  - home/
  - var/
  - usr/
    - bin/
    - sbin/
  - tmp

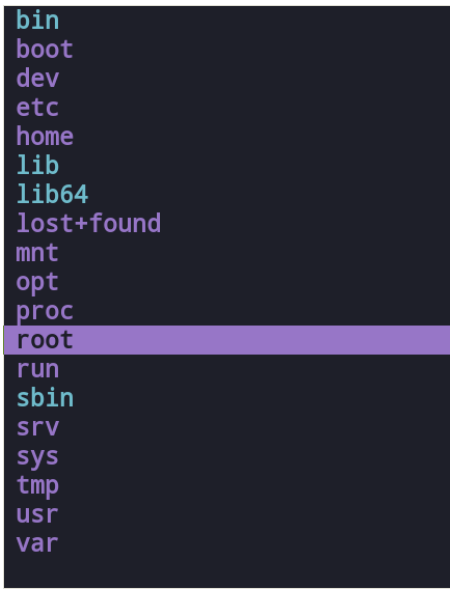

(На картинке изображен типичный вид корня в Linux)

1.8 Монтирование

- Есть корень и есть узлы, в которые можно монтировать другие файловые системы (часть из них виртуальная)
- **$ mount**
- Для / обычно используется **ext4** (использует журналирование)
- Для /boot может использоваться **ext2** — так как это более проверено временем (на Ubuntu)
- Файловая система для узла — это не константа, ее можно менять
- **$ df - h** , **$ du -hs**

1.9 Inode

- Директория задает mapping имени файла в его inode
- **$ ln**
- Hardlink — существует в рамках одной файловой системы
- Softlink(symlink) — text string
- **$ stat** — информация о файле
- *atime* — время последнего доступа
- *ctime* — изменение мета-информации
- *mtime*— изменение содержимого файла
- inode корневой файловой системы фиксирован — 2

1.10 Проход по пути

- Рекурсивный процесс (увеличиваем индекс при проходе в глубину)
- Количество seek по диску зависит от длины пути
- namei (name-innode) — lru-cache (файл <–> номер inode)

1.11 Атрибуты процесса

1.11.1 Structures

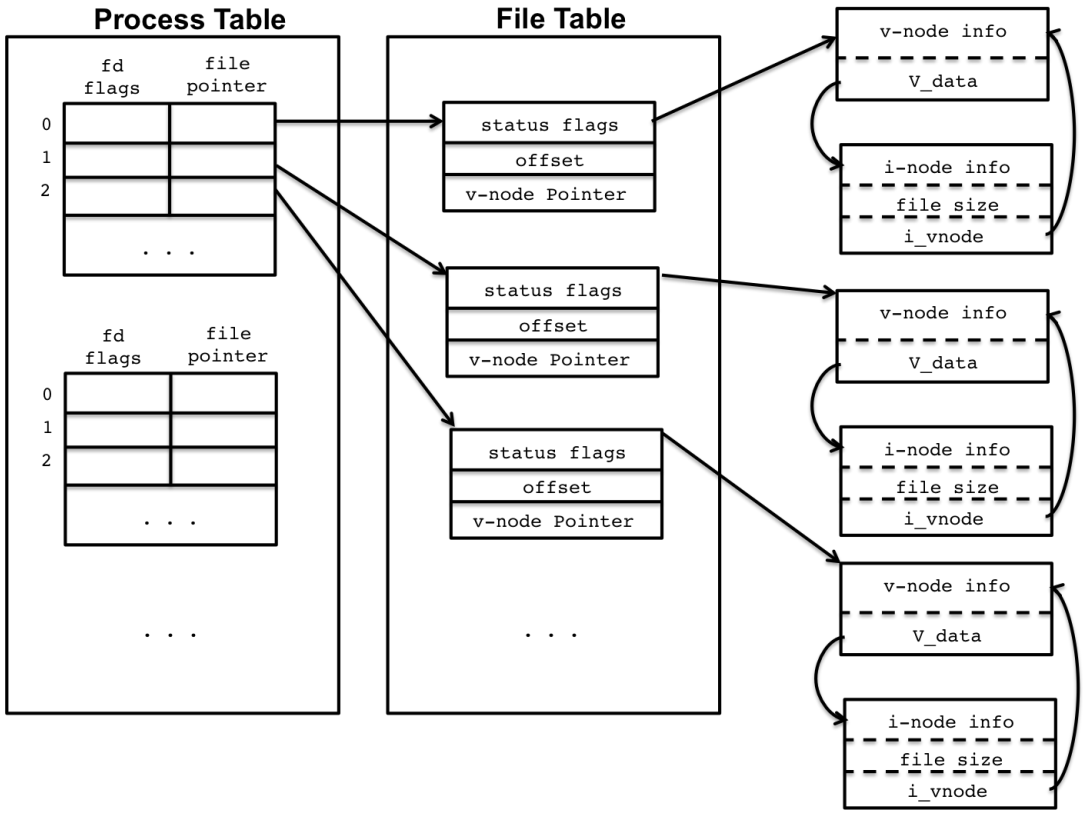

Рис. 1.2: Kernel structures

1.11.2 Duplication and sharing

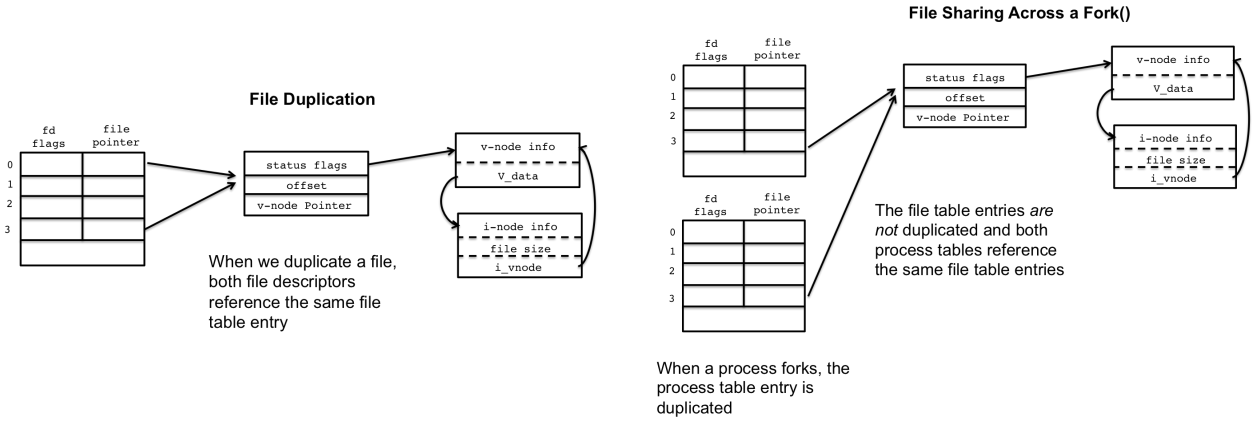

Рис. 1.3: Duplication and sharing

1.11.3 Deep view

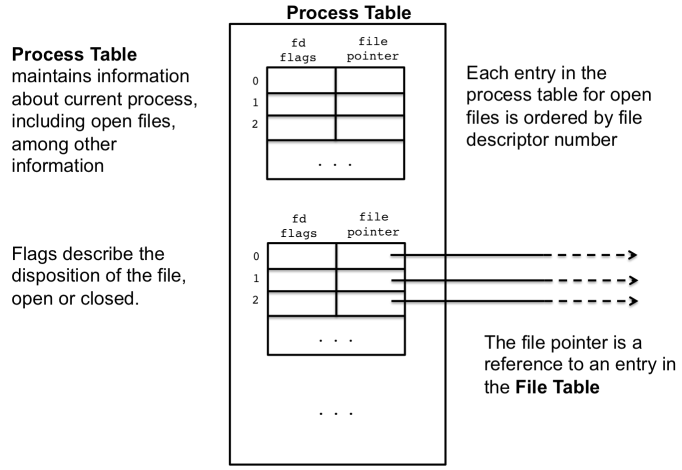

Рис. 1.4: Processes

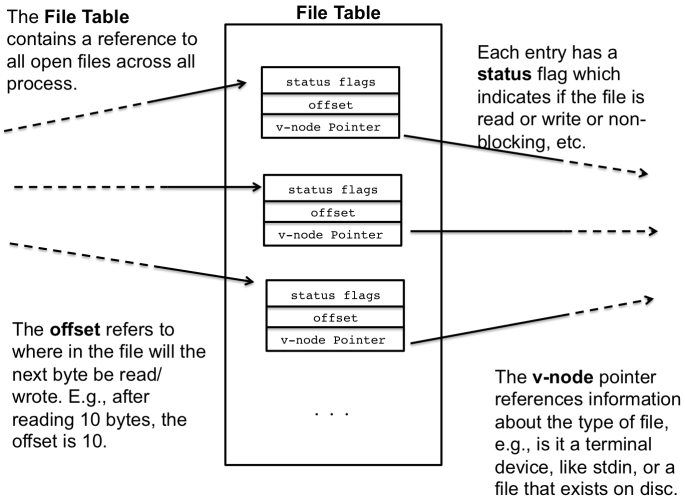

Рис. 1.5: Files

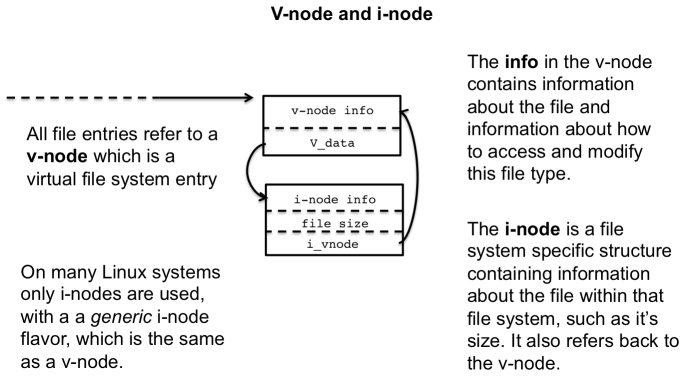

Рис. 1.6: Vnode and Inode

1.12 Файловые системы

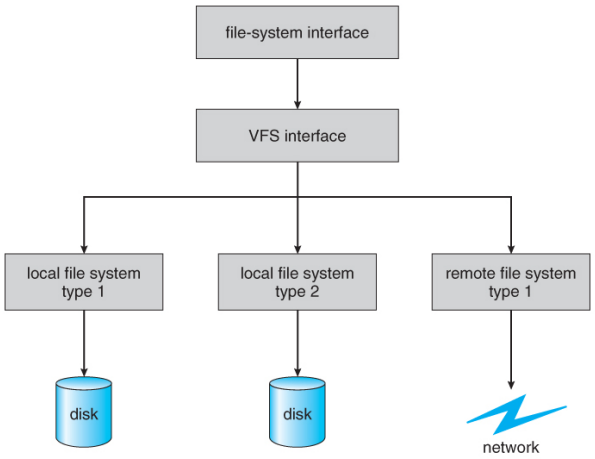

Виды

- **VFS**
- Сетевые
- Виртуальные
- На диске
- В памяти

TODO Описания

1.13 Диски

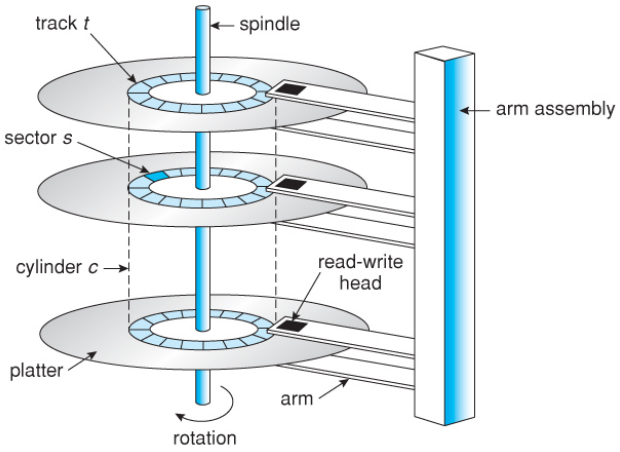

Рис. 1.7: Устройство диска

- Устройство диска:
  - сектор
    - header: метаданные для контроллера диска
    - данные
    - trailer: ECC
  - цилиндр
  - пластина
  - трэк
  - шпиндель

- При записи данных на диск в сектора считаем и записываем **ECC**, при чтении считаем и затем сверяем (пытаемся исправить, если не сошлось)
- **CLV** — Constant Linear Velocity(**CDROM**)
- **CAV** — Constant Angular Velocity(**HDD**)
- На внешних цилиндрах больше секторов, чем на внутренних => чем ближе к центру тем меньше скорость нужна (CD)
- На жестких дисках — постоянная угловая скорость (в центре больше плотность)
- *Partitioning* — разделение диска на несколько логических частей (партиции, на каждой своя файловая система), они трактуются как "отдельные"диски
- Существует другой подход - "собственная"файловая система на "сыром"диске (MySQL)
- Современный контроллер жесткого диска может находить механически поврежденные блоки (bad blocks) и делать remap их на некоторые запасные (sector sparing: replace bad sectors with spare)
- **$ man 1 badblocks**
- Bootblock — bootstrap program at fixed location
- **MBR** — master boot record — boot code + partition table

1.14 RAID

Redundant Arrays of Independent Disks (Избыточный массив независимых дисков)

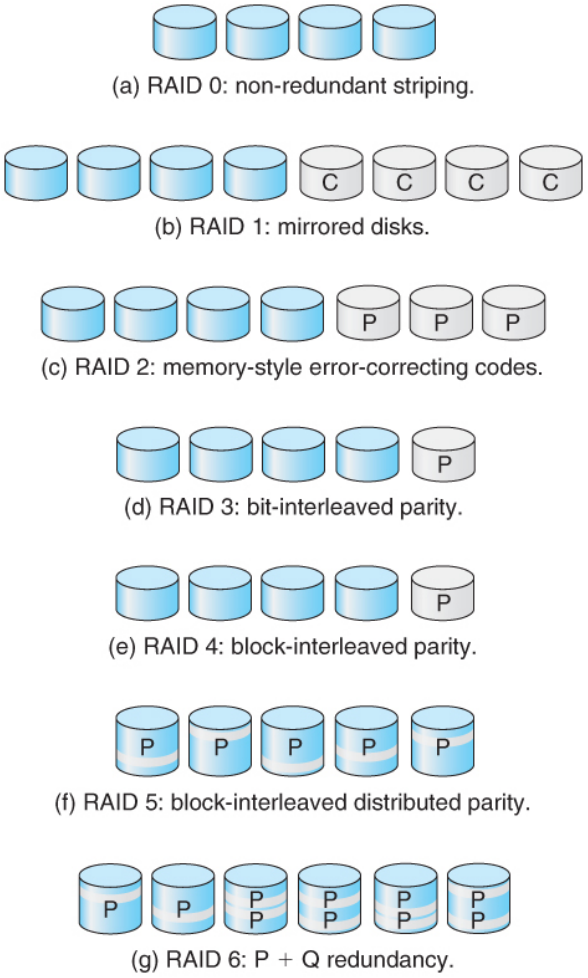

- Reilability (надежность, hacks for more long time of complex usage)
- Perfomance (striping, суммирование **IOPS**)
- Levels:
  - **0** — pure striping (1 блок на 1 диске, 2 блок на 2 диске и т.д. — один диск вышел из строя — fail)
  - **1** — pure mirroring (пара дисков, данные продублированы)
  - **0 + 1, 1 + 0**
  - **2, 3, 4, 5** — используются не так часто (хранение доп. данных)
- Rebuild — падает производительность
- Hardware RAID — проблемы: "заложенность"на производителе (vendor lock in), драйвера, как правило, не очень
- Software RAID — гипотетически медленно, но на практике нужная производительность достигается
- У аппаратных RAID — есть батарейка, которая "улучшает"производительность (сначала на батарейку, потом на диск, когда будет удобно)
- TODO Байка про SpaceWeb

1.15 Организация файловых систем

Структура директорий: связный список или хэш-таблица
smart (**$ smartctl**) — оценка диска на практике
Свободные сектора

1. Bit Vector — fast, space usage
2. Список

Выделение памяти (allocation)

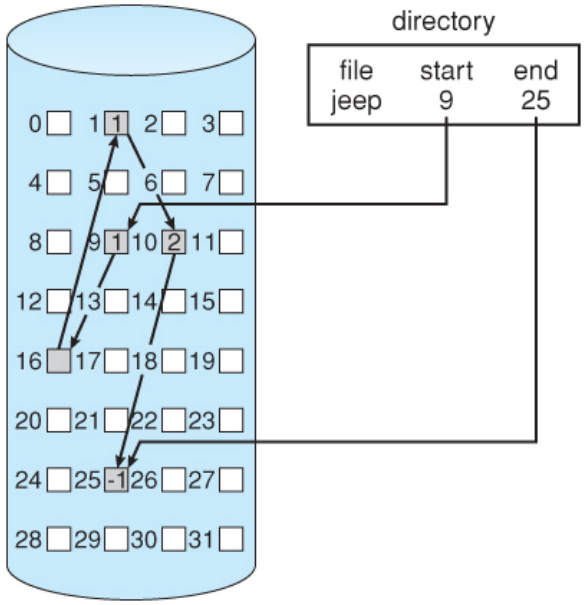

Линейное

- Объект задается началом и концом (здесь возникают проблемы внешней и внутренней фрагментации)
- Линейное чтение, меньше обращений
- Perfomance: sequential, random

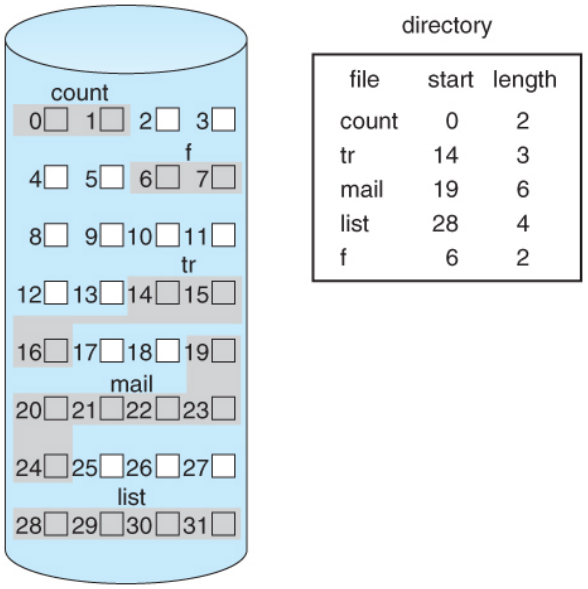

Список

- В каждом "блоке"указатель на следующий
- Плюсы: решает проблему внешней фрагментации
- Минусы: надежность, прыгаем по памяти
- Perfomance: sequential, awful random

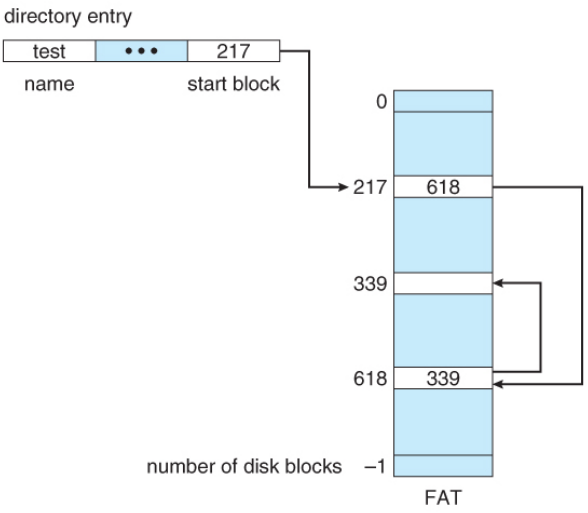

FAT

- Все ссылки хранятся в начале диска — их можно эффективно кэшировать
- Улучшенный поиск

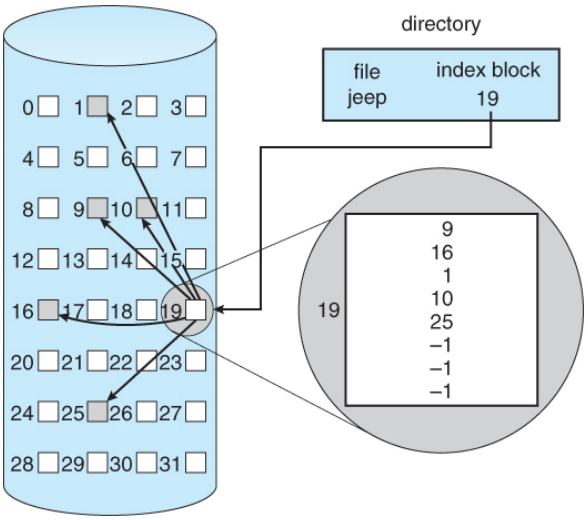

Indexed

- Отдельный блок для ссылок на данные
- Внутренняя фрагментация

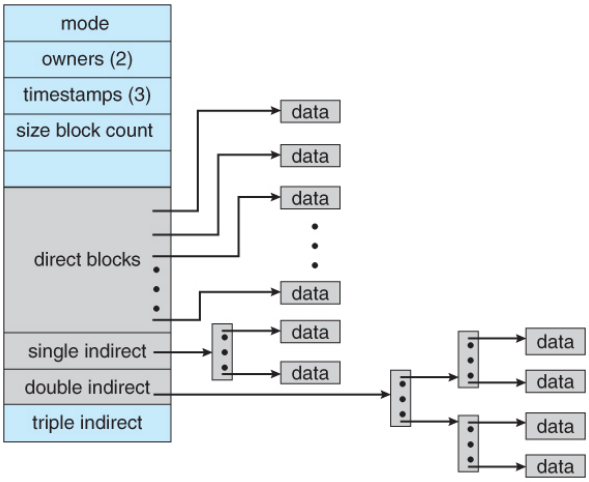

UNIX

- Комбинированная
- Косвенная многоуровневая адресация

1.16 Операции с файлами

TODO 3 картинки + презентация

1.17 Системные вызовы

TODO

1.18 Пару слов о типах

Лучше всего использовать следующие типы данных:
TODO Why?

- **off_t**
- **size_t**
- **ssize_t**

1.19 Common pitfalls

- Неатомарные операции (окно **race**)
- Утечка дескрипторов
- Файловая система гарантирует, что до тех пор пока ты держишь файловый дескриптор на файл с ним ничего не произойдет извне (функции оканчивающиеся на *"at"*, защита от **TOCTOU**)
- *openat*

1.20 Литература

- The Unix Programming Environment. Brian W. Kernighan, Rob Pike
- Advanced Programming in the Unix Environment. W. Richard Stevens

1.21 Домашнее задание №2

Необходимо написать подмножество утилиты find.
Программа должна:

- Первым аргументом принимать абсолютный путь, в котором будет производиться поиск файлов.
- По умолчанию выводить в стандартный поток вывода все найденные файлы по этому пути

- Поддерживать аргумент **-inum num**. Аргумент задает номер инода
- Поддерживать аргумент **-name name**. Аргумент задает имя файла
- Поддерживать аргумент **-size [—=+]size**. Аргумент задает фильтр файлов по размеру(меньше, равен, больше)
- Поддерживать аргумент **-nlinks num**. Аргумент задает количество hardlink'ов у файлов
- Поддерживать аргумент **-exec path**. Аргумент задает путь до исполняемого файла, которому в качестве единственного аргумент нужно передать найденный в иерархии файл
- Поддерживать комбинацию аргументов. Например хочется найти все файлы с размером больше 1GB и скормить их утилите /usr/bin/sha1sum.
- Выполнять поиск рекурсивно, в том числе во всех вложенных директориях.
- Сильные духом призываются к выполнению задания с использованием системного вызова *getdents(2)*. Остальные могут использовать *readdir* и *opendir* для чтения содержимого директории.